客户购物行为数据分析报告

一、业务背景与问题定义

一家领先的零售公司希望更深入地了解客户的购物行为，从而提升销售额、客户满意度和长期忠诚度。管理层注意到，不同人口统计群体、产品类别以及销售渠道（线上与线下）的购买模式存在差异。他们尤其希望查明哪些因素——例如折扣、用户评价、季节或支付偏好——会影响消费者的决策并促使其重复购买。

本报告围绕一个核心问题展开：公司如何利用消费数据识别趋势、提升客户参与度、优化营销和产品策略？

由此拆解出三个具体子问题：

- 哪些因素（折扣、订阅、配送方式）驱动了消费金额？
- 客户如何分层，新客、回头客、忠诚客的分布如何？
- 不同品类、年龄段的营收贡献结构如何？

二、数据说明

数据来源为公开零售数据集（Customer Shopping Trends），共 3900 行、18 列。字段按性质分为四类：

- 客户属性：Age（年龄）、Gender（性别）、Location（地区）
- 交易属性：Item Purchased（商品）、Category（品类）、Purchase Amount（消费金额）
- 行为属性：Subscription Status（订阅）、Discount Applied（折扣）、Previous Purchases（历
  史购买次数）、Frequency of Purchases（购买频率）、Shipping Type（配送方式）
- 内容属性：Review Rating（商品评分，存在 37 个缺失值）

三、数据清洗与特征工程

在 Python（pandas）中完成清洗与特征工程后，导入 MySQL 数据库 customer_analysis.customer 表。

（1）数据清洗

- 补齐缺失值：Review Rating 存在 37 个缺失（占 0.95%），按“品类中位数”填补。选择中位数而非均值，是因为评分是离散偏态数据，中位数对极端值更稳健；按品类分层填补，则考虑到不同品类的评分基准存在差异。
- 删除冗余列：Promo Code Used 与 Discount Applied 在全部 3900 行中 100% 一致，属于信息冗余，删除前者以避免口径混乱。
- 列名标准化：统一转为 snake_case（如 purchase_amount、review_rating），提升可读性与规范性。

（2）特征工程

- 生成 age_group：将连续的 Age 用四分位数（qcut）等分为 Young Adult / Adult / Middle-aged / Senior 四档，用于年龄段营收分析。
- 生成 purchase_frequency_days：将“购买频率”文本（Weekly、Monthly 等）映射为间隔天数，使无序文本转为可计算数值。

四、核心发现

以下发现均由 SQL 查询在 customer 表上计算得出，采用“数字 → 业务含义 → 建议”结构呈现。

发现 1：服装品类贡献近半营收，且营收优势并非靠折扣拉动

Clothing（服装）品类营收 104264 元，占总营收的 44.73%，是最大的营收来源；Accessories（配饰）以 31.83% 位居第二，Footwear（鞋）15.5%、Outerwear（外套）7.9%。

业务含义：服装的规模领先，并非源于更激进的折扣——四个品类的折扣率几乎一致（均在 42%–44% 之间，其中服装 42.1% 反而最低，外套 44.4% 最高）。同时，折扣使用率 Top5 的商品（Hat、Sneakers、Coat、Sweater、Pants）均匀分布在四个品类中，不存在某一品类“过度依赖折扣”的现象。这表明折扣是平台级的通用促销手段，而非服装品类的专属增长驱动。

建议：服装品类的增长应归因于其“品类规模与需求”本身，而非折扣杠杆。营销资源不应继续向服装品类倾斜折扣，而应关注两点：① 巩固服装的规模优势（品类丰富度、连带销售）；② 对占比仅 7.9% 但折扣率最高（44.4%）的外套品类，评估其折扣是否真正带来增量、还是仅维持现状。

发现 2：订阅用户与非订阅用户客单价几乎持平，但订阅用户是“忠诚度更高”的群体

订阅用户客单价 59.49 元，非订阅用户 59.87 元，两者几乎持平；订阅用户仅占 27%（1053 人），非订阅占 73%（2847 人）。

业务含义：订阅并未带来更高的单次消费。但进一步看，订阅用户中“忠诚客”（历史购买 >10 次）占比达 82.5%，高于非订阅用户的 78.9%。这说明订阅用户群体本身由更多高复购客户构成。

建议：订阅权益的设计目标不应是“提升客单价”，而应是将高复购客户转化为订阅、并以订阅进一步锁定复购。基于此，运营重点应放在“复购但未订阅”的客户上（这类客户既有忠诚潜力、又有转化空间），同时把订阅占比（27%）作为可提升的核心指标。

发现 3：客户基本盘高度依赖忠诚客，新客占比严重不足

按历史购买次数分层，客户结构呈极端的「倒三角」：忠诚客（历史购买 >10 次）占全体客户的 79.9%（3,116 人），回头客（2 – 10 次）占 18.0%（701 人），而新客（仅 1 次）只占 2.1%（83 人）。

业务含义：这个客户基本盘几乎完全由高复购的老客支撑，新客占比严重不足。近八成客户已是忠诚客，说明存量客户经营得不错、复购能力强；但新客仅 2.1%，意味着拉新能力是明显的短板——如果长期依赖存量，增长空间将日益收窄，且一旦老客流失，营收会迅速塌陷。

建议：应将“拉新”提为核心议题：① 复盘新客占比 2.1% 的成因（渠道投放不足、获客成本过高、还是新客转化后快速流失）；② 明确拉新与留存的资源分配——当前存量基本盘稳固，应把增量资源更多投向获客；③ 对新客建立“首购后复购”的专项培育，避免“拉来即流失”，否则拉新也无法转化为基本盘的扩大。

发现 4：性别营收差异源于“人数”，而非“消费力”

男性贡献营收 157890 元（占 67.8%），女性 75191 元（32.2%）；但客单价几乎一致——男性 59.54 元、女性 60.25 元。

业务含义：营收的性别差异主要由客户数量结构（男性 68%、女性 32%）驱动，而非男女消费力差异。

建议：女性客单价略高，说明女性客户价值不低，可针对性提升女性获客；男性作为规模基本盘，重点在维持与复购。

发现 5：配送方式与年龄结构对客单价的区分度很低，不构成营收的主要驱动因素

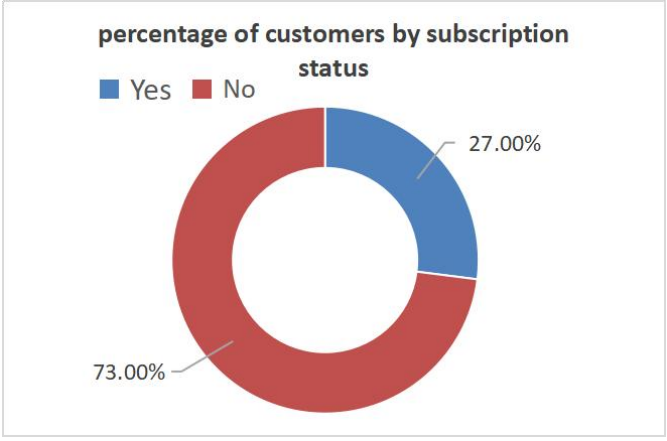
6 种配送方式的平均客单价高度接近，从 Standard 的 58.46 元到 2-Day Shipping 的 60.73 元，最高与最低之间仅相差约 2.3 元，各配送方式间差异微弱。各年龄段的营收同样相对均衡（Young Adult 62143 元最高，Senior 55763 元最低）。

业务含义：无论客户选择哪种配送方式、处于哪个年龄段，消费金额都没有明显分化。这意味着配送方式和年龄对营收的驱动作用很弱，不宜作为核心经营变量。

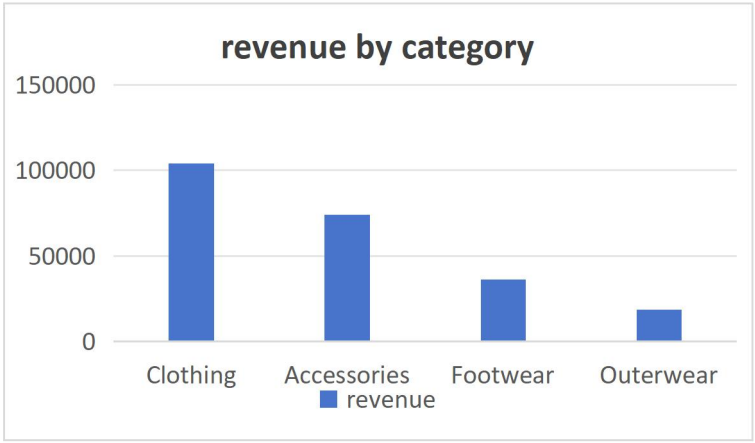
建议：营销和运营资源应优先投向“品类结构”（发现 1）和“订阅与拉新”（发现 2、3）这两条主线。配送方式和年龄可作为辅助的细分标签，用于精准触达，但不应期待通过调整它们带来显著的营收增长。

五、可视化

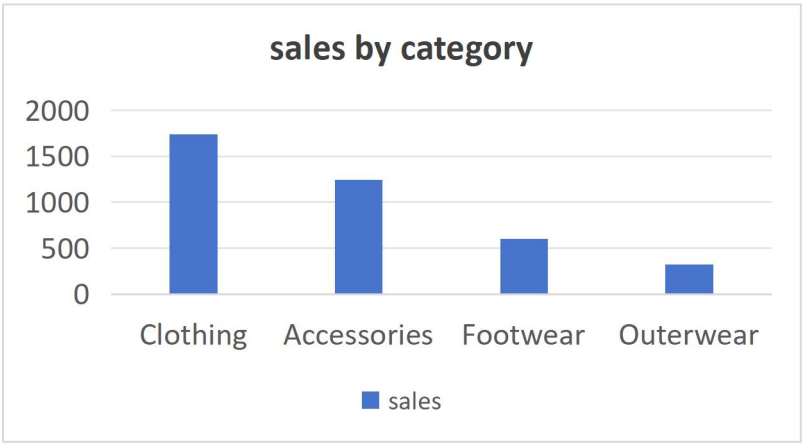
订阅占比（环形图）：Yes 27% / No 73%



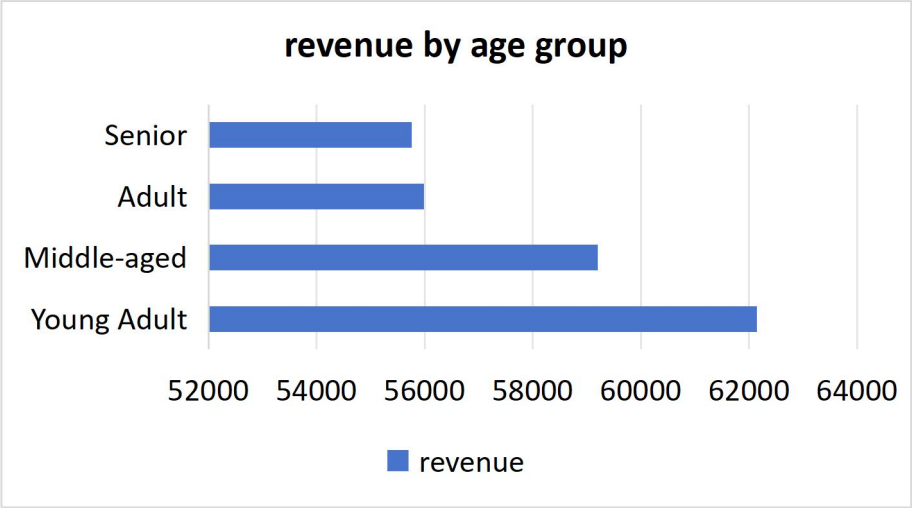
各品类营收（柱状图）：Clothing 44.7% 领先



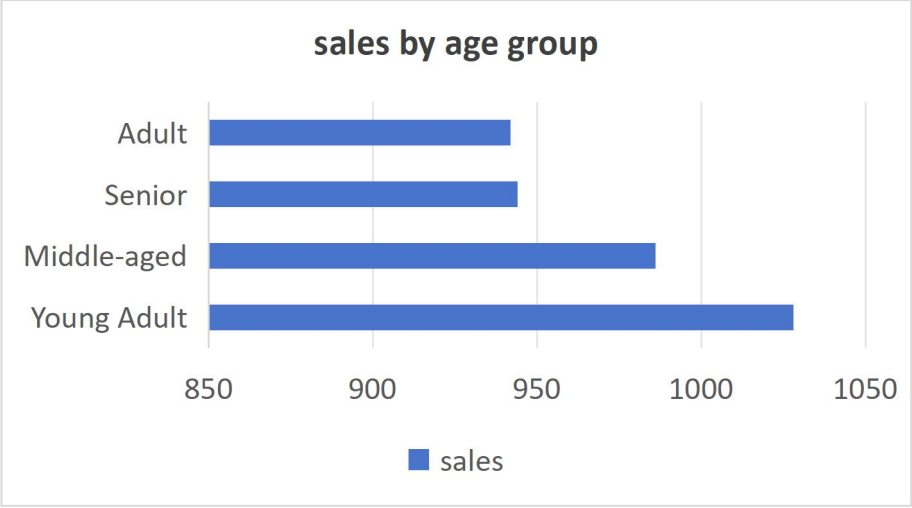
各品类销量（柱状图）：Clothing 1737 单最高



各年龄段营收（条形图）：Young Adult 最高



各年龄段销量（条形图）：四档均衡



六、结论与建议

综合上述发现，给出两个层面的可执行化建议;

1. 营销侧

- 优先提升订阅转化率：针对“复购但未订阅”客户定向推送订阅权益，目标将订阅占比从 27% 提升。
- 加强女性与新客的获客：女性客单价略高、新客占比过低，均存在增长空间。

2. 产品与品类侧

- 服装品类差异化运营：维持折扣保规模，同时以连带销售提升客单，警惕折扣依赖侵蚀利润。
- 强化高评分商品曝光：评分 Top5 商品（Gloves、Sandals、Boots、Hat、Handbag）可作为活动主推。